

Machine Learning First Assignment

唐永承
4105053128
國立中興大學應用數學系

I. INTRODUCTION

訊號分離的目標是要讓一個混合的訊號分離成原本所組成的成分。假設 y 是一個由兩個不同圖片所混合的訊號

$$y = \sum_{i \in C} x_i + \epsilon \quad (1)$$

$\{x_i\}_{i \in C}$ 是 y 所組成的成分。使用特定演算法讓 y 分離為 $\{x_i\}_{i \in C}$ 。以圖 1. 為例，將 y 拆分為 x_1 與 x_2 。圖 2. 則是訊號分離的相關應用，可將下雨得痕跡移除。



圖 1. 訊號分離示意圖




圖 2. 訊號分離相關應用

II. BACKGROUND

A. Sparse Approximation

假設有 L 個訊號，可表示為 $Y = [y_1, \dots, y_L] \in \mathbb{R}^{N \times L}$ ，且有個字典 $D = [d_1, \dots, d_M] \in \mathbb{R}^{N \times M}$ ，然後稀疏近似問題可寫為

$$\arg \min_{A \in \mathbb{R}^{M \times L}} \frac{1}{2} \|Y - DA\|_F^2 + \lambda \Omega(A) \quad (2)$$

這裡 $\Omega(A)$ 表示一個函數計算稀疏程度，也就是計算矩陣中每行 L_0 範數的合 $\Omega(A) = \sum_i \|A_{:,i}\|_0$ ， λ 則是用來平衡的正規化參數，通常會用貪婪演算法來解，例如匹配追蹤 (Matching Pursuit, MP) 或正交匹配追蹤 (Orthogonal Matching Pursuit, OMP)。若用 L_1 範數來替代 L_0 範數，則可使用這些凸化演算法：ISTA、FISTA 或 ADMM 來解。

然而當面對較大的訊號時，常常會切成數個小塊，不過分割成小塊可能會破壞影像的結構，因此使用卷積稀疏編碼 (Convolutional Sparse Coding, CSC) 會是一個更好的方式，利用卷積來替代矩陣相乘，且字典元素也不需要和訊號有著相同形狀。讓 $D = \{d_1, \dots, d_M\}$ 為一個有 M 個元素的字典，且使用 $*$ 表示卷積，因此 CSC 問題可表示為

$$\arg \min_{\{\alpha_{l,m}\}} \frac{1}{2} \sum_l \left\| \sum_m d_m * \alpha_{l,m} - y_l \right\|_F^2 + \lambda \sum_l \sum_m \Omega(\alpha_{l,m}) \quad (3)$$

l 表示訊號的編號， $\alpha_{l,m}$ 為第 m 個字典對第 l 個訊號的係數圖 (coefficient map)，且 d_m 可以與 y_l 有著不同的形狀。當 $\Omega(\alpha_{l,m})$ 是一個 L_0 的稀疏程度計算的函數，就可以使用匹配追蹤 (MP) 或正交匹配追蹤 (OMP) 等貪婪演算法解此問題，此外若使用 L_1 來近似 L_0 ，也可以使用凸優化演算法來解此問題，例如：FISTA、ADMM。

B. Dictionary Learning

通常字典學習是試圖解以下問題

$$\arg \min_{D, A} \frac{1}{2} \|Y - DA\|_F^2 + \lambda_1 \Omega(A) + \lambda_2 \sum_m \Gamma_C(d_m) \quad (4)$$

在此字典 D 是藉由稀疏矩陣 A 來近似大量訊號 Y ，然後定義指示函數為

$$\begin{aligned} \Gamma_S(x) &= 0, \text{ if } x \in S \\ \Gamma_S(x) &= \infty, \text{ otherwise} \end{aligned} \quad (5)$$

這裡 S 為一些集合，指示函數會把 S 內的元素映射到 0，其他則映射到無限大。在式 (4) 中，字典長度被指示函數 Γ_C 所限制， C 是一個非凸單位曲面 ($\|d_m\|_2^2 = 1$) 或一個非凸單位球 ($\|d_m\|_2^2 \leq 1$)。如同稀疏編碼可延伸至卷積稀疏編碼，字典學習也可進一步延伸至卷積字典學習，問題可寫為以下式子

$$\arg \min_{\{\alpha_{l,m}\}, \{d_m\}} \frac{1}{2} \sum_l \left\| \sum_m d_m * \alpha_{l,m} - y_l \right\|_F^2 + \lambda_1 \sum_l \sum_m \Omega(\alpha_{l,m}) + \lambda_2 \sum_m \Gamma_C(d_m) \quad (6)$$

在此式子中， $\{d_m\}$ 是由數個字典元素所組成，同時為了近似 $\{y_l\}$ ，卷積稀疏近似可藉由式 (3) 來根據已學習到的字典來解。

通常會使用交替更新的迭代演算法，每次迭代包含兩步驟，分別為稀疏編碼和字典更新。在第一步時，可固定字典並使用式子 (2) 或 (3) 來解並獲得稀疏解，在第二步時，則更新字典。第一步在上面已提過，第二步字典學習可使用 Method of Optimal Directions (MOD) 演算法或 K-SVD 演算法。概念上來說，MOD 是基於最小平方法，K-SVD 則是基於 K-means 演算法。近年來有許多其他的方法，都是由這兩個方法所延伸的。

C. Singal Separation

在參考論文 [1]，作者使用稀疏字典學習來解訊號分離問題，並將問題寫為

$$y = y_c + y_t \quad (7)$$

讓 $y \in \mathbb{R}^{N \times N}$ ， $y_c \in \mathbb{R}^{N \times N}$ ， $y_t \in \mathbb{R}^{N \times N}$ ，假設 y 是由兩個不同影像相加， y_c 為卡通或較平滑的圖像， y_t 為紋理圖案。作者將會對兩種類型的圖片使用卷積稀疏編碼 (CSC) 分別先訓練各自的濾波器。在 CSC 中，會先使用 M 張

訓練圖片 $\{y_m\}_{m=1}^M$ ，目標是學習出一組卷積式的濾波器 (Convolutional Filters) $\{d_k\}_{k=1}^K$ ，藉由解出以下最佳化問題

$$\arg \min_{d,x} \frac{1}{2} \sum_{m=1}^M \left\| y_m - \sum_{k=1}^K d_k * x_{m,k} \right\|_2^2 + \lambda \sum_{m=1}^M \sum_{k=1}^K \|x_{m,k}\|_1 \quad (8)$$

$x_{m,k} \in \mathbb{R}^{N \times N}$ 是對於訓練資料 y_m 的稀疏表示， λ 為正規化參數。分別學習好卡通和紋理圖案的字典 $\{d_{c,k}\}_{k=1}^{K_c}$ 和 $\{d_{t,k}\}_{k=1}^{K_t}$ ，然後卡通圖片和紋理圖片可表示成 $y_c = \sum_{k=1}^{K_c} d_{c,k} * x_{c,k}$ 和 $y_t = \sum_{k=1}^{K_t} d_{t,k} * x_{t,k}$ ，最後再解以下最佳化問題

$$\arg \min_{x_{c,k}, x_{t,k}} \frac{1}{2} \|y - \sum_{k=1}^{K_c} d_{c,k} * x_{c,k} - \sum_{k=1}^{K_t} d_{t,k} * x_{t,k}\|_2^2 + \lambda_c \sum_{k=1}^{K_c} \|x_{c,k}\|_1 + \lambda_t \sum_{k=1}^{K_t} \|x_{t,k}\|_1 + \beta TV(\sum_{k=1}^{K_c} d_{c,k} * x_{c,k}) \quad (9)$$

一旦得到 $\hat{x}_{c,k}$ 和 $\hat{x}_{t,k}$ ，即可分離為卡通圖片 $\hat{y}_c = \sum_{k=1}^{K_c} d_{c,k} * \hat{x}_{c,k}$ 和紋理圖片 $\hat{y}_t = \sum_{k=1}^{K_t} d_{t,k} * \hat{x}_{t,k}$ 。

III. PROPOSED MODEL

A. Signal separation with two dictionaries

如以下式子，預計使用兩個字典，分別學習兩類圖片，並加上一些限制來使兩個字典正交

$$\arg \min_{D_1, D_2, x_1, x_2} \|y_1 - D_1 x_1\|_F^2 + \|y_2 - D_2 x_2\|_F^2 + \lambda \|D_1^T D_2\|_F^2 + \Gamma_x(x_1) + \Gamma_x(x_2) + \Gamma_D(D_1) + \Gamma_D(D_2) \quad (10)$$

這裡 y_1 和 y_2 分別是兩類圖片， D_1 和 D_2 分別為對應兩類圖片的字典， x_1 和 x_2 是分別對應的稀疏表示， λ 為正規化參數， Γ_x 和 Γ_D 分別為稀疏限制式以及字典標準化。

利用學習完畢的兩個字典來分類混合的訊號，如以下式子

$$\arg \min_{\hat{x}_1, \hat{x}_2} \|y - D_1 \hat{x}_1 - D_2 \hat{x}_2\|_F^2 + \Gamma_x(\hat{x}_1) + \Gamma_x(\hat{x}_2) \quad (11)$$

最後可獲得分離後得到 $D_1 \hat{x}_1$ 和 $D_2 \hat{x}_2$ 。

B. Signal separation with three dictionaries

如以下式子，預計使用三個字典，分別學習兩類圖片，並加上一些限制來使 D_1 和 D_2 兩個字典與第三個共同字典 D 正交，第三個字典目標要吸收掉無法分類的特徵

$$\arg \min_{D_1, D_2, x_1, x_2} \|y_1 - D_1 x_1 - D \bar{x}_1\|_F^2 + \|y_2 - D_2 x_2 - D \bar{x}_2\|_F^2 + \lambda \|D_1^T D_2\|_F^2 + \lambda_1 \|D^T D_1\|_F^2 + \lambda_2 \|D^T D_2\|_F^2 + \Gamma_x(x_1) + \Gamma_x(x_2) + \Gamma_D(D_1) + \Gamma_D(D_2) + \Gamma_D(D) \quad (12)$$

這裡 y_1 和 y_2 分別是兩類圖片， D_1 和 D_2 分別為對應兩類圖片的字典， x_1 和 x_2 是分別對應的稀疏表示， \bar{x}_1 和 \bar{x}_2 是分別對應 D 的稀疏表示， λ 為正規化參數， Γ_x 和 Γ_D 分別為稀疏限制式以及字典標準化。

利用學習完畢的兩個字典來分類混合的訊號，如以下式子

$$\arg \min_{\hat{x}_1, \hat{x}_2, x} \|y - D_1 \hat{x}_1 - D_2 \hat{x}_2 - D x\|_F^2 + \Gamma_x(\hat{x}_1) + \Gamma_x(\hat{x}_2) \quad (13)$$

最後可獲得分離後得到 $D_1 \hat{x}_1$ 和 $D_2 \hat{x}_2$ 。

IV. EXPERIMENT RESULT

A. Experiment result of two dictionaries

先前訓練出一組字典，分別都有 64 個 atoms， x 則有 6 個非零數值，且 $\lambda = 100$ 、 $\|D_1^T * D_2\|_F = 0.3490$ 、 $\|D_1^T * D_1\|_F = 36.9216$ 、 $\|D_2^T * D_2\|_F = 41.0088$ 。

做訊號分離的稀疏編碼時，丟入(11)式的 y 為當初訓練獲得的 $y = D_1 x_1 + D_2 x_2$ ，結果分離出的兩張圖與原始的 $D_1 x_1$ 和 $D_2 x_2$ 的 psnr 分別為 34.4100 和 30.5587。

B. Experiment result of three dictionaries

先前訓練出一組字典， D_1 和 D_2 分別有 64 個 atoms， D 則有 64 個 atoms， x 有 6 個非零數值， \bar{x} 有 3 個非零數值，且 $\lambda = 100$ 、 $\lambda_1 = 10$ 、 $\lambda_2 = 10$ 、 $\|D_1^T * D_2\|_F = 0.5138$ 、 $\|D^T * D_1\|_F = 0.2322$ 、 $\|D^T * D_2\|_F = 0.2190$ 。

做訊號分離的稀疏編碼時，丟入(13)式的 y 為當初訓練獲得的 $y = D_1 x_1 + D_2 x_2 + D \bar{x}_1 + D \bar{x}_2$ ，結果分離出的兩張圖與原始的 $D_1 x_1$ 和 $D_2 x_2$ 的 psnr 分別為 34.0296 和 30.6101。

V. CONCLUSION

從實驗的結果可以看出經由稀疏編碼得到的 x 與訓練時所得到的 x 的非零數值是在不同的位置上，稀疏編碼得到的 x 並沒有收斂到與訓練時一樣的解，故猜測 x 的初始值有重要的影響，因此下次實驗預計先加入 L1 proximal mapping。先使用 L1 讓這問題變成凸優化問題，進而得到較固定的起始值，接著再使用 L0 proximal mapping 來求得最後解。