

# Machine Learning Second Assignment

唐永承  
4105053128  
國立中興大學應用數學系

## I. INTRODUCTION

訊號分離的目標是要讓一個混合的訊號分離成原本所組成的成分。假設  $y$  是一個由兩個不同圖片所混合的訊號

$$y = \sum_{i \in C} x_i + \epsilon \quad (1)$$

$\{x_i\}_{i \in C}$  是  $y$  所組成的成分。使用特定演算法讓  $y$  分離為  $\{x_i\}_{i \in C}$ 。以圖 1. 為例，將  $y$  拆分為  $x_1$  與  $x_2$ 。圖 2. 則是訊號分離的相關應用，可將下雨得痕跡移除。



圖 1. 訊號分離示意圖




圖 2. 訊號分離相關應用

## II. BACKGROUND

### A. Sparse Approximation

假設有  $L$  個訊號，可表示為  $Y = [y_1, \dots, y_L] \in \mathbb{R}^{N \times L}$ ，且有個字典  $D = [d_1, \dots, d_M] \in \mathbb{R}^{N \times M}$ ，然後稀疏近似問題可寫為

$$\arg \min_{A \in \mathbb{R}^{M \times L}} \frac{1}{2} \|Y - DA\|_F^2 + \lambda \Omega(A) \quad (2)$$

這裡  $\Omega(A)$  表示一個函數計算稀疏程度，也就是計算矩陣中每行  $L_0$  範數的合  $\Omega(A) = \sum_i \|A_{:,i}\|_0$ ， $\lambda$  則是用來平衡的正規化參數，通常會用貪婪演算法來解，例如匹配追蹤 (Matching Pursuit, MP) 或正交匹配追蹤 (Orthogonal Matching Pursuit, OMP)。若用  $L_1$  範數來替代  $L_0$  範數，則可使用這些凸化演算法：ISTA、FISTA 或 ADMM 來解。

然而當面對較大的訊號時，常常會切成數個小塊，不過分割成小塊可能會破壞影像的結構，因此使用卷積稀疏編碼 (Convolutional Sparse Coding, CSC) 會是一個更好的方式，利用卷積來替代矩陣相乘，且字典元素也不需要和訊號有著相同形狀。讓  $D = \{d_1, \dots, d_M\}$  為一個有  $M$  個元素的字典，且使用  $*$  表示卷積，因此 CSC 問題可表示為

$$\arg \min_{\{\alpha_{l,m}\}} \frac{1}{2} \sum_l \left\| \sum_m d_m * \alpha_{l,m} - y_l \right\|_F^2 + \lambda \sum_l \sum_m \Omega(\alpha_{l,m}) \quad (3)$$

$l$  表示訊號的編號， $\alpha_{l,m}$  為第  $m$  個字典對第  $l$  個訊號的係數圖 (coefficient map)，且  $d_m$  可以與  $y_l$  有著不同的形狀。當  $\Omega(\alpha_{l,m})$  是一個  $L_0$  的稀疏程度計算的函數，就可以使用匹配追蹤 (MP) 或正交匹配追蹤 (OMP) 等貪婪演算法解此問題，此外若使用  $L_1$  來近似  $L_0$ ，也可以使用凸優化演算法來解此問題，例如：FISTA、ADMM。

### B. Dictionary Learning

通常字典學習是試圖解以下問題

$$\arg \min_{D, A} \frac{1}{2} \|Y - DA\|_F^2 + \lambda_1 \Omega(A) + \lambda_2 \sum_m \Gamma_C(d_m) \quad (4)$$

在此字典  $D$  是藉由稀疏矩陣  $A$  來近似大量訊號  $Y$ ，然後定義指示函數為

$$\begin{aligned} \Gamma_S(x) &= 0, \text{ if } x \in S \\ \Gamma_S(x) &= \infty, \text{ otherwise} \end{aligned} \quad (5)$$

這裡  $S$  為一些集合，指示函數會把  $S$  內的元素映射到 0，其他則映射到無限大。在式 (4) 中，字典長度被指示函數  $\Gamma_C$  所限制， $C$  是一個非凸單位曲面 ( $\|d_m\|_2^2 = 1$ ) 或一個非凸單位球 ( $\|d_m\|_2^2 \leq 1$ )。如同稀疏編碼可延伸至卷積稀疏編碼，字典學習也可進一步延伸至卷積字典學習，問題可寫為以下式子

$$\arg \min_{\{\alpha_{l,m}\}, \{d_m\}} \frac{1}{2} \sum_l \left\| \sum_m d_m * \alpha_{l,m} - y_l \right\|_F^2 + \lambda_1 \sum_l \sum_m \Omega(\alpha_{l,m}) + \lambda_2 \sum_m \Gamma_C(d_m) \quad (6)$$

在此式子中， $\{d_m\}$  是由數個字典元素所組成，同時為了近似  $\{y_l\}$ ，卷積稀疏近似可藉由式 (3) 來根據已學習到的字典來解。

通常會使用交替更新的迭代演算法，每次迭代包含兩步驟，分別為稀疏編碼和字典更新。在第一步時，可固定字典並使用式子 (2) 或 (3) 來解並獲得稀疏解，在第二步時，則更新字典。第一步在上面已提過，第二步字典學習可使用 Method of Optimal Directions (MOD) 演算法或 K-SVD 演算法。概念上來說，MOD 是基於最小平方法，K-SVD 則是基於 K-means 演算法。近年來有許多其他的方法，都是由這兩個方法所延伸的。

### C. Singal Separation

在參考論文 [1]，作者使用稀疏字典學習來解訊號分離問題，並將問題寫為

$$y = y_c + y_t \quad (7)$$

讓  $y \in \mathbb{R}^{N \times N}$ ， $y_c \in \mathbb{R}^{N \times N}$ ， $y_t \in \mathbb{R}^{N \times N}$ ，假設  $y$  是由兩個不同影像相加， $y_c$  為卡通或較平滑的圖像， $y_t$  為紋理圖案。作者將會對兩種類型的圖片使用卷積稀疏編碼 (CSC) 分別先訓練各自的濾波器。在 CSC 中，會先使用  $M$  張

訓練圖片  $\{y_m\}_{m=1}^M$ ，目標是學習出一組卷積式的濾波器 (Convolutional Filters)  $\{d_k\}_{k=1}^K$ ，藉由解出以下最佳化問題

$$\arg \min_{d,x} \frac{1}{2} \sum_{m=1}^M \left\| y_m - \sum_{k=1}^K d_k * x_{m,k} \right\|_2^2 + \lambda \sum_{m=1}^M \sum_{k=1}^K \|x_{m,k}\|_1 \quad (8)$$

$x_{m,k} \in \mathbb{R}^{N \times N}$  是對於訓練資料  $y_m$  的稀疏表示， $\lambda$  為正規化參數。分別學習好卡通和紋理圖案的字典  $\{d_{c,k}\}_{k=1}^{K_c}$  和  $\{d_{t,k}\}_{k=1}^{K_t}$ ，然後卡通圖片和紋理圖片可表示成  $y_c = \sum_{k=1}^{K_c} d_{c,k} * x_{c,k}$  和  $y_t = \sum_{k=1}^{K_t} d_{t,k} * x_{t,k}$ ，最後再解以下最佳化問題

$$\arg \min_{x_{c,k}, x_{t,k}} \frac{1}{2} \|y - \sum_{k=1}^{K_c} d_{c,k} * x_{c,k} - \sum_{k=1}^{K_t} d_{t,k} * x_{t,k}\|_2^2 + \lambda_c \sum_{k=1}^{K_c} \|x_{c,k}\|_1 + \lambda_t \sum_{k=1}^{K_t} \|x_{t,k}\|_1 + \beta TV(\sum_{k=1}^{K_c} d_{c,k} * x_{c,k}) \quad (9)$$

一旦得到  $\hat{x}_{c,k}$  和  $\hat{x}_{t,k}$ ，即可分離為卡通圖片  $\hat{y}_c = \sum_{k=1}^{K_c} d_{c,k} * \hat{x}_{c,k}$  和紋理圖片  $\hat{y}_t = \sum_{k=1}^{K_t} d_{t,k} * \hat{x}_{t,k}$ 。

### III. PROPOSED MODEL

如以下式子，預計使用兩個字典，分別學習兩類圖片，並加上一些限制來使兩個字典正交

$$\arg \min_{D_1, D_2, x_1, x_2} \|y_1 - D_1 x_1\|_F^2 + \|y_2 - D_2 x_2\|_F^2 + \lambda \|D_1^T D_2\|_F^2 + \Gamma_x(x_1) + \Gamma_x(x_2) + \Gamma_D(D_1) + \Gamma_D(D_2) \quad (10)$$

這裡  $y_1$  和  $y_2$  分別是兩類圖片， $D_1$  和  $D_2$  分別為對應兩類圖片的字典， $x_1$  和  $x_2$  是分別對應的稀疏表示， $\lambda$  為政規化參數， $\Gamma_x$  和  $\Gamma_D$  分別為稀疏限制式以及字典標準化。

利用學習完畢的兩個字典來分類混合的訊號，如以下式子

$$\arg \min_{\hat{x}_1, \hat{x}_2} \|y - D_1 \hat{x}_1 - D_2 \hat{x}_2\|_F^2 + \Gamma_x(\hat{x}_1) + \Gamma_x(\hat{x}_2) \quad (11)$$

最後可獲得分離後得到  $D_1 \hat{x}_1$  和  $D_2 \hat{x}_2$ 。

#### A. Training method 1

1. 初始化  $D_1, D_2, x_1$  和  $x_2$
  2. 同時更新  $D_1, D_2, x_1$  和  $x_2$ ，且  $x$  使用 greedy algorithm 作為 proximal mapping
  3. 固定  $D$ ，使用 L1 proximal mapping 更新  $x$
  4. 更新  $\lambda$  (Threshold)，使用第六大的  $x$  作為新的  $\lambda$
  5. 同時更新  $D_1, D_2, x_1$  和  $x_2$ ，且  $x$  使用 L0 proximal mapping
- 重複 3 到 5 步，直到收斂

#### B. Training method 2

1. 初始化  $D_1, D_2, x_1$  和  $x_2$
  2. 同時更新  $D_1, D_2, x_1$  和  $x_2$ ，且  $x$  使用 greedy algorithm 作為 proximal mapping
  3. 固定  $D$ ，使用 L1 proximal mapping 更新  $x$ ， $\lambda$  選擇每個 cloumn 絕對值的平均值
  4. 同時更新  $D_1, D_2, x_1$  和  $x_2$ ，且  $x$  使用 greedy algorithm
- 重複 3, 4 步，直到收斂

## IV. EXPERIMENT RESULT

#### A. Training method 1

$D_1$  和  $D_2$  各有 64 個 atoms， $\|D_1^T D_2\| = 0.0217$ ， $\|D_1^T D_1\| = 29.4929$ ， $\|D_2^T D_2\| = 25.5423$ ， $D_1 x_1$  psnr: 23.9891， $D_2 x_2$  psnr: 24.6949。不過  $x$  沒有稀疏，因為很難選擇是當的  $\lambda$ 。

#### B. Training method 2

$D_1$  和  $D_2$  各有 64 個 atoms， $\|D_1^T D_2\| = 0.0379$ ， $\|D_1^T D_1\| = 25.5144$ ， $\|D_2^T D_2\| = 24.1014$ ， $D_1 x_1$  psnr: 23.6192， $D_2 x_2$  psnr: 22.8900。

接著使用 B 這組來做 sparse coding

$$\begin{aligned} y_{mixture} &= D_1 x_1 + D_2 x_2 \\ D_1 x_1 (x \text{ by sparse coding}) &\text{ vs. } D_1 x_1 \text{ psnr: 45.6391} \\ D_2 x_2 (x \text{ by sparse coding}) &\text{ vs. } D_2 x_2 \text{ psnr: 38.3082} \\ y_{mixture} &= y_1 + y_2 \\ D_1 x_1 (x \text{ by sparse coding}) &\text{ vs. } D_1 x_1 \text{ psnr: 29.0641} \\ D_2 x_2 (x \text{ by sparse coding}) &\text{ vs. } D_2 x_2 \text{ psnr: 25.2943} \\ D_1 x_1 (x \text{ by sparse coding}) &\text{ vs. } y_1 \text{ psnr: 22.7642} \\ D_2 x_2 (x \text{ by sparse coding}) &\text{ vs. } y_2 \text{ psnr: 22.0339} \end{aligned}$$

## V. CONCLUSION

可以看出當  $y_{mixture} = D_1 x_1 + D_2 x_2$  分離的效果很好，不過當  $y_{mixture} = y_1 + y_2$  時，分離效果受到剩餘能量影響變差，因此這是要再處理的問題。接下來可能會再加上 Analysis Dictionary 來限制，以增加分離效果。