

機器學習-人臉辨識

第二次

楊郁成 8107053002

藉由過去的研究了解人臉辨識在傳統統計方法運行方式，並且試著使用過去的方法將圖片中的雜訊(光亮位置) 或是一種新型的方式進行人臉辨識。並且透過傳統的PCA 由主成份的線性組合擴展到非線性的特徵空間或是改進降為的技術，予以計算的主成份獲得更好的性能與提高分類準確性。

I. 論文一

A. 介紹

Belhumeur et.al. (1997)[1] 開發了一種臉部識別算法，該算法對光照方向和臉部表情的總體變化較不敏感，可識別具有干擾的部份(如 Fig.1)。將圖像中的每個像素視為高維空間中的坐標。我們將透過該篇論文提供的模擬，先使用相機進行人臉的收集，收集後進行影像處理(如談諧化、正規化、人臉位置對齊與標籤化)，1. 談諧化: 將圖片轉為黑白。2. 正規化: 將圖片維度一樣。3. 人臉位置對齊: 這邊將使用手動定位，透過相機九宮格的方式，將上緣部份切眼睛、左右切耳朵與下緣部份切下巴，使其每張人臉最具特徵的部分(如 眼皮嘴) 在中心。4. 標籤化: 將每張圖標記名子。我將預計針對圖片有陰影的部分，對每張圖每一行進行遞增加入雜訊(如 Fig. 2 所示) 進行模擬研究。透過以下方式進行比較:



Fig. 1. 每個受試者皆有不同表情或是不同光線的干擾




Fig. 2. 不同光線角度下的圖片。

B. 方法一: 相關性方法

相關性方法(Correlation Method) 或許是現今最直觀的方法，此方法為最簡單的最近鄰分類器，通過將學習集中最接近點的標籤分配給測試集中的圖像來識別測試集中的圖像，該位置

在圖像空間中進行距離測量。如果所有圖像均已標準化為零均值並具有單位方差，則此過程等效於在學習集中選擇與測試圖像最相關的圖像。由於進行了歸一化處理，理論上與光源強度以及攝像機自動增益控制的效果無關。

在這裡可能需要對比該論問提出的問題。首先，如果學習集和測試集中的圖像是在變化的光照條件下收集的，則圖像空間中的對應點將不會緊密地聚類。因此，為了使該方法在光照變化下可靠地工作，我們需要一個巨大的學習集，該學習集對可能的光照條件的連續體進行密集採樣。其次，相關性在計算上非常費時。為了識別，我們必須將測試面部的圖像與學習集中的每個圖像相關聯。最後，它需要大量圖片提供協助。

C. 方法二: 特徵臉

特徵臉(Eigenfaces) 由於相關方法在計算上很昂貴並且需要大量存儲，因此追求降維方案是很自然的。我們只需要找到每個圖片的特徵(Eigen vector)，並且一步一步進行重建，即可解決陰影。在這裡將所有圖片變為向量並合為一個 $X_{p \times n}$ 的矩陣，其中 n 為照片數、 p 每張的維度。矩陣相乘得到一個正定矩陣($L = X^T X$)，針對 L 進行特徵值分解求得特徵向量(或稱特徵臉)，並透過這一判斷式

$$W_{opt} = \operatorname{argmax} |W^T S_T W| \quad (1)$$

其中 $S_T = \sum (X_k - \mu)(X_k - \mu)^T$ 。在PCA 中，選擇最佳投影 W_{opt} 以最大程度地確定投影樣本的總散佈矩陣的決定因素。此論文使用此方法將前幾個主成份視為捕捉到光影反應的影響，如果識別掉前幾個主成份，可以處理光影的效果。但是我想前幾個主成份不僅僅解釋了光影，可能會丟失有助於歧視的信息。當然我們不能得知第幾主成份解釋了什麼現象。該論文提到此方法的缺點在於，最大化散佈不僅是由於可用於分類的組間散佈，而且是出於分類目的是不需要的信息的組內變異。因此，如果在變化的照明下向PCA 呈現人臉圖像，則投影矩陣 W_{opt} 將包含主要成分(即特徵臉)，這些主要成分在投射的特徵空間中保留由於光照引起的變化。因此，投影空間中的點將無法很好地分類，更糟糕的是，這些組可能會被塗抹在一起。

D. 方法三: 費雪臉

費雪臉(Fisherfaces) 線性子空間算法利用了以下事實: 在理想條件下，這些類是線性可分離的。但是，可以使用線性投影執行降維，同時仍保持線性可分離性。使用線性決策邊界，在較低維度的特徵空間中，仍然可以在任何光照條件下進行無誤分類。這是一個有力的論據，贊成至少在人們對光照條件不敏感的情況下，使用線性方法來減少人臉識別問題的維數。

在這裡，我們認為，在降維特徵空間中使用類特定的線性方法進行降維並使用簡單的分類器，與線性子空間方法相比，在較短的時間內可以獲得更好的識別率。由於標記了學習集，因此使用

此信息來構建更可靠的方法來減少特徵空間的維數是有意義的。Fisher 的線性判別式(FLD)[3] 是類特定方法的一個示例, 從某種意義上說, 它試圖塑造散點圖以使其更可靠地進行分類。該方法選擇最佳投影 W_{opt} 作為最大化 S 的組間散佈矩陣的行列式比率的投影。投影樣本到投影樣本的類內散佈矩陣的行列式, 即

$$W_{opt} = \operatorname{argmax}_W \frac{|W^T S_b W|}{|W^T S_w W|} \quad (2)$$

其中組間散佈公式為 $S_b = \sum |x_i|(\mu_i - \mu)(\mu_i - \mu)^T$ 與組內變異公式 $S_w = \sum (X_k - \mu)(X_k - \mu)^T$ 。在這裡我們緊需要對 $S_w^{-1} S_b$ 找特徵向量 W 即可計算。

但在找尋特徵向量 W 過程中, 往往計算 S_w 的行向量是困難的, 因為 S_w 總是奇異(Singular) 沒有行向量。這是由於 S_w 的秩小於 $N-c$, 並且通常情況下, 每個圖像(n) 中的像素遠大於學習集中(N) 中圖像的數量, 這意味著可以選擇矩陣 W , 使投影樣本的類內散佈可以精確地設為零。

為了處理 S_w 的問題。該篇論文提出了Eq.(2) 中準則的另一種選擇。這種方法(稱為Fisherfaces) 可以避免通過將圖像集投影到較低維度的空間來解決此問題, 從而使所得的組內散佈矩陣 S_w 為非奇異的。這是通過使用PCA 將特徵空間的尺寸減小到 $N-c$, 然後應用由等式3 定義的標準FLD 將尺寸減小到 c 1 來實現的。如下

$$\begin{aligned} W_{opt} &= W_{fld} W_{pca} \\ W_{pca} &= \operatorname{argmax}_W |W^T S_T W| \\ W_{fld} &= \operatorname{argmax}_W \frac{|W^T W_{pca} S_b W_{pca} W|}{|W^T W_{pca} S_w W_{pca} W|} \end{aligned}$$

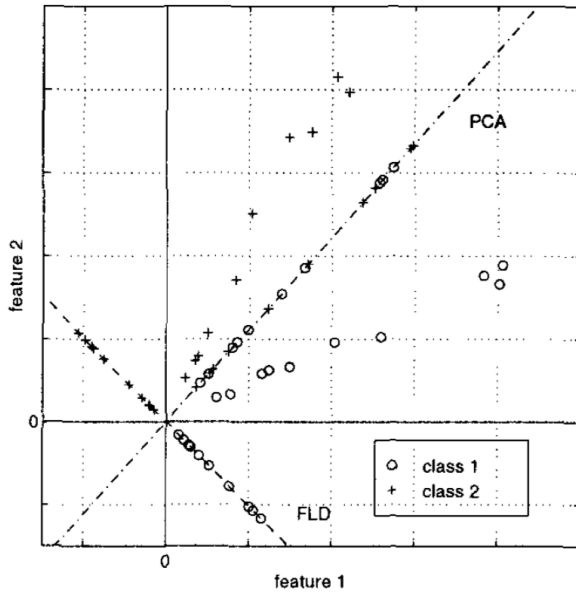


Fig. 3. 取前兩因子或主成份視為 x 與 y 軸。

II. 論文二

A. 介紹

在資料中,PCA 的線性組合過於強烈再人臉辨識中。Kim et al. (2002)[2] 提出新的PCA 可以適應非線性, 作為PCA 的非線性的擴展, 稱之為核主成分分析(kernel

principal component analysis; kernel PCA)。基本思想是首先通過非線性映射將輸入空間投射到特徵空間(函數 Φ), 然後計算該特徵空間中的主成分。採用內 kernel PCA 作為提取面部特徵的機制。通過採用多項式 kernel, 可以在構成面部圖像的輸入像素的高階相關所跨越的空間內計算主成分, 從而產生良好的性能。

為了進行主成分提取, 將的投影計算到特徵向量中。結構包含三層完全不同的步驟。輸入層由將 kernel PCA 連接到其環境的節點組成。其激活來自臉部圖像的灰度值。隱藏層從輸入空間到要素空間應用非線性頭射在要素空間中計算內積。這兩個操作是使用 kernel 一步完成的。然後, 使用權重對輸出進行線性組合, 得出對應的非線性主成分。此後, 第一主成分(假設特徵向量以其特徵值大小的降序排列) 構成了臉部的特徵向量。

當然的, 我們很難計算該函數 Φ 該如何假設。所以我們只需要將矩陣與矩陣進行內積求其解, 即可。如下:

$$\begin{aligned} (\Phi_d(\mathbf{x}) \cdot \Phi_d(\mathbf{y})) &= \sum_{i_1, \dots, i_d=1}^N x_{i_1} \cdot \dots \cdot x_{i_d} \cdot y_{i_1} \cdot \dots \cdot y_{i_d} \\ &= \left(\sum_{i=1}^N x_i \cdot y_i \right)^d = (\mathbf{x} \cdot \mathbf{y})^d. \end{aligned}$$

Fig. 4. 取前兩因子或主成份視為 x 與 y 軸。

相關步驟介紹: 首先, 藉由非線性函式 Φ 將原空間資料 x_i 對映於高維度空間 F 。接下來滿足此一不等式 $Cw_i = \lambda_i w_i$ 與傳統PCA 極為相似, 其中 C 為變異數共變異數矩陣(Variance-covariance Matrix)。最後, 在論文中使用 Polynomial Kernel 方法找到 K 。最後在比較。

REFERENCES

- [1] P.N. Belhumeur, J.P. Hespanha and D.J. Kriegman, "Eigenfaces vs. Fisherfaces: recognition using class specific linear projection," *IEEE Transl. Pattern Anal. Machine Intell.*, vol. 19, pp. 711–720, Jul. 1997.
- [2] K.I. Kim, K. Jung and H.J. Kim, "Face recognition using kernel principal component analysis," *IEEE Signal Processing Letters*, vol. 9, pp. 40–42, Feb. 2002.
- [3] Y. Cheng, K. Liu, J. Yang, Y. Zhuang, and N. Gu, "Human Face Recognition Method Based on the Statistical Model of Small Sample Size," *SPIE Proc. Intelligent Robots and Computer Vision X: Algorithms and Technology*, pp. 85–95, 1991.